

Overlapping MoE Pre-Barriers with Data Transfer Using In-Network Computing

主线：rank 本地就绪后先上传，INC 同时收集 READY 并暂存早到数据；接收条件满足后转发，把等待其他 rank 就绪的时间用于搬运数据。

1. Introduction — 引言

- **问题**：小 batch 缩短 token 传输，但 pre-barrier 仍需等待同一组 rank，开销难以摊薄。
- **观测**：H200 跨机 EP8 Direct 的 pre-barrier 约 15 μ s，小 batch 时约占算子 20%；真实跨机 decode 中约占 GPU step 的 15%–17%。
- **思想**：将“开始上传”和“允许写入目标 buffer”分开。INC 汇总 READY 的同时接收数据，就绪后转发。
- **贡献**：pre-barrier 开销测量、提前上传协议，以及完整通信操作的时延分析。

2. Background and Motivation — 背景与动机

2.1 Expert-Parallel Communication

介绍 Dispatch $\rightarrow$ expert compute $\rightarrow$ Combine。路由决定 token 的目标，计数和布局元数据决定接收后的组织方式。READY 表示本轮通信所需资源可用。

典型发送前协调方式：NCCL EP HT 先汇总路由；DeepEP V2 Direct 先执行 pre-barrier，再并行处理计数与数据；NCCL EP LL 向预留槽位写入并使用细粒度信号。

2.2 Pre-Barriers in DeepEP V2 Direct

Direct 已采用 GPU 发起传输和预分配接收 buffer。Dispatch 由不同 warps 并行处理计数 / 布局和 token 传输，Combine 复用 Dispatch 建立的路由。

这些传输在 pre-barrier 之后开始：每个 rank 等待参与者就绪并完成本地同步，因此本地已有 token 也不能提前发送。固定 EP8，T/rank 从 8 增至 128 时，pre-barrier 约保持 15 μ s，占比从约 20% 降至约 5%。由此引出在收集 READY 时先上传本地数据的机会。

2.3 Opportunities for In-Network Computing

INC 可在转发时维护哪些 rank 已就绪，并暂存早到 token。所有相关通信经过 INC 时，可将上传与 READY 汇总并行组织。

Key Insight：本地数据就绪后即可上传到网络暂存区，目标写入仍等待所需就绪条件。这样 pre-barrier 的等待过程可以与部分数据传输重叠。


3. Design — 设计

3.1 Protocol Overview

A Direct: wait, then upload



B INC: upload while collecting READY



Earlier upload; destination writes still wait for readiness.

INC 为每轮维护 READY bitmap 和有上限的数据队列。generation 标识一次 Dispatch/Combine，epoch 区分接收 buffer 的不同轮使用。相关参与者及数据路径需纳入相同的就绪判定范围。

接收 buffer 在初始化时按 symmetric memory 分配、注册，布局 and 访问映射一次性建立。token 路由和标识决定目标及写入偏移，不依赖全局计数。READY 确认本地输入可用，且目标 buffer 已结束上一轮使用。

3.2 Overlapping Readiness Collection with Upload

rank 发布 READY 后开始上传，不等其他 rank 的 READY 返回。READY 携带 rank、generation、epoch；路由随 token 传输，必要计数和元数据按原通信流程处理，不把完整 count vector 作为 READY 的前置条件。

INC 忽略重复和旧轮次消息。所需 READY 未收齐时暂存 DATA；就绪且目标可写后，按路由转发缓存和新到 token。Dispatch 接收后按 expert 整理；Combine 将 expert outputs 送回 token owner 完成合并。

3.3 Buffer Reuse and Flow Control

接收 buffer 的最后一次读取完成后才可复用，下一轮 READY 确认这一点。发送 buffer 保留到发送硬件读完。INC 在队列排空且所有 rank 进入下一轮后回收旧轮 READY 状态。

PFC 在缓存溢出前暂停 DATA，并预留 headroom 接纳暂停生效前的在途数据。READY 与必要控制元数据有独立优先级和预留资源，避免暂停 DATA 时阻塞就绪消息。

4. Latency Analysis — 时延分析

4.1 Communication Latency Model

完整 Dispatch/Combine 分为 READY、DATA、post-barrier。DATA 包含进入后同步前必需的发送侧工作；后同步项包含本地收尾。

$$T_{\text{base}} = T_{\text{ready}} + T_{\text{data}} + T_{\text{post}}.$$


借鉴 Swift 区分处理与网络时延，在参与者同时就绪的参考条件下：

$$T_{\text{ready}} = T_{\text{issue}} + L + T_{\text{observe}}.$$


T_{issue} 是本地准备并发出 READY 的时间； L 是 READY 的单向网络传播； T_{observe} 是接收后检查信号与完成本地同步的时间。

4.2 Latency Reduction from Early Upload


A Simultaneous readiness: Direct




B Simultaneous readiness: INC



C Unequal readiness: Direct



D Unequal readiness: INC



Dashed: READY Solid: DATA Schematics show readiness and data delivery; spacing is illustrative.

INC 保留本地发起工作，随后让 DATA 上传与 READY 传播重叠；目标写入仍等就绪条件满足。在参考数据传输和后同步工作相同的条件下：

$$T_{\text{INC}} = T_{\text{issue}} + T_{\text{data}} + T_{\text{post}} + T_{\text{extra}}.$$

T_{extra} 包括仍需执行的就绪处理及额外缓存 / 放行等待。DATA 自身的源到目标传播已包含在 T_{data} 中。

$$\text{收益 } \Delta T = L + T_{\text{observe}} - T_{\text{extra}}.$$

网络部分的参考收益是 L ：对称路径下约半个网络 RTT。其含义不是整个实测 pre-barrier 时长的一半，净收益还取决于观察工作和新增处理成本。

4.3 Overlap with Unequal Readiness

实际运行中，计算与调度差异使 rank 常常错峰就绪。Figure 2(C-D) 中早到 rank 在等待期间上传，最后一个 READY 到达后，INC 可直接转发缓存中的 token，无需再等源端接收 peer 信号后才启动上传，因此机制不依赖同步到达。

暂存和转发能力充足时，这一上传提前量能在错峰场景中保留；若提前了关键路径上的数据交付，就能缩短完整操作。出口排队和 PFC 的额外等待计入 T_{extra} ，收益大小随到达时序及最后完成的 rank 而变化。

5. Evaluation — 实验评估

回答三个问题：pre-barrier 如何随 token 数变化、在不同 EP 配置中是否持续存在，以及它在真实 MoE serving step 中占多大比例。

5.1 Experimental Setup and Methodology

- 两台 H200，各八卡；机内 NVSwitch，机间八轨 400GbE RoCE。Direct、GDAKI3、TC162。
- 微基准：H=7168、topk=8、E=256、BF16、balanced/uniform。每点三轮独立进程，每轮 200 次有效迭代。
- 每次选 pre-barrier 最短的 rank，除以同 rank 同轮 trace-on 算子时间；该口径减少慢 rank 到达差的影响，但选中 rank 仍可能等待。误差为三轮均值的样本标准差。
- EP8 token sweep 与 EP-size 表来自不同采集批次；表格常数只拟合表中列出的点。
- 同镜像 EP8/T8 on/off 检查中，Dispatch 总时延差 3.9%—5.0%，Combine 为 1.7%—3.8%；阶段占比使用同次 trace-on 分子与分母。
- 推理每个 client 窗口采样一个 active GPU step。decode 每个活跃 rank 均采样；prefill 只统计实际执行的 active step。

5.2 Effect of Token Count

H200 跨机 EP8 Direct：

T/rank	Dispatch pre-barrier 占比	Combine pre-barrier 占比
8	(20.57 ± 0.06)%	(19.84 ± 0.13)%
32	(12.25 ± 0.17)%	(12.26 ± 0.26)%
64	(8.29 ± 0.51)%	(8.20 ± 0.16)%
128	(4.88 ± 0.04)%	(5.05 ± 0.19)%

四档绝对时长均约 15 μs；固定的就绪成本在小 token batch 下最难摊薄。来源：[配对数值](#)；[主图源码](#)。

5.3 Pre-Barrier Cost across EP Sizes

各固定 EP 配置的常数估计使用全部所列 token 档，每档三轮：

EP 卡数	T/rank	Dispatch (μs)	Combine (μs)	各档均值最大偏差 (μs)
4	8/32/96/128	11.65	11.54	0.06
8	8/32/64/96/128	14.96	14.94	0.16
16	8/32/96/128	18.36	18.28	0.09

pre-barrier 均值从 EP4 的约 11.6 μs 增至 EP16 的约 18.3 μs；每个 EP 配置内部，各 token 档的均值变化不超过 0.16 μs。每机卡数、目标分布和网络并发随 EP 配置共同改变，数值反映其综合效果。来源：[拟合数值](#)。

5.4 Pre-Barrier Share in MoE Inference

Qwen3-30B-A3B，BF16、TP1/EP8 Direct，实际路由。这里的占比是一个 sampled GPU step 内 48 次 Dispatch 与 48 次 Combine 的 pre-barrier 累计时间；不同于 §5.2 的单算子占比。

拓扑	并发	实测 token/rank	D+C pre-barrier 占 GPU step
单机 1n8	1	1	(9.26 ± 0.15)%
单机 1n8	64	8	(9.33 ± 0.12)%
单机 1n8	128	16	(7.94 ± 0.15)%
单机 1n8	256	32	(7.61 ± 0.32)%
跨机 2n4	64	8	(16.72 ± 0.10)%
跨机 2n4	128	16	(15.19 ± 0.05)%

C1 是低负载锚点，每个窗口只有一个 active rank；三个 client 窗口复用同一 server 实例。

扩展跨机对照：

EP	工作负载	T/rank	pre-barrier 占 GPU step
4	Decode C64	16	(14.75 ± 0.21)%
8	Decode C128	16	(15.19 ± 0.05)%
16	Decode C256	16	(15.04 ± 0.12)%
8	Prefill	512	(2.64 ± 0.06)%
8	Prefill	2048	(3.13 ± 0.39)%

Request concurrency. 低并发只激活部分 rank；C16 起两种拓扑都激活 8 个 rank。C16—C256，单机占比从 14.91% 降至 7.61%，跨机从 18.73% 降至 14.22%。
EP scale and workload. 相同 16 token/rank 下，跨机 EP4/8/16 均约为 15%；512/2048 token 的 prefill 占比为 2.6%—3.1%。大 token batch 更充分地摊薄了重复的 READY 开销。来源：[扩展汇总](#)、[原始汇总](#)；[主图源码](#)。

6. Related Work — 相关工作

6.1 EP Communication

[DeepEP](#) 与 [NCCL EP](#) 提供 EP 数据路径与不同发送前协调方式。[SwiftEP](#)、[Perseus](#)、[UBEP](#) 改进数据移动和传输过程中的协调。本文用网络暂存重叠发送前的就绪等待。

6.2 In-Network Computation

[SHARP](#)、[SwitchML](#) 展示网内归约与状态管理；[DySHARP](#)、[MultiWrite](#) 将网络处理用于 MoE 数据交换。本文利用临时状态和缓存改变 pre-barrier 与上传的先后关系。

6.3 Synchronization and Delay Analysis

[EPIC](#) 的 INC 协议和资源抽象、[GPU-Initiated Networking](#) 的端点原语为实现提供基础。[Swift](#) 提供处理/网络时延分解思路，[FabricPerf](#) 强调明确的计时边界。

7. Conclusion — 结论

小 batch 下 pre-barrier 开销显著。INC 允许本地就绪的 rank 在等待期间提前上传，并在接收条件满足后转发。收益取决于暂存空间、就绪时间差和转发速率。