

Overlapping MoE Pre-Barriers with Data Transfer Using In-Network Computing

主线：rank 本地就绪后先上传，INC 同时收集 READY 并暂存早到数据；接收条件满足后转发，把等待其他 rank 就绪的时间用于搬运数据。

1. Introduction — 引言

- **问题**：小 batch 缩短 token 传输，但 pre-barrier 仍需等待同一组 rank，开销难以摊薄。
- **观测**：H200 跨机 EP8 Direct 的 pre-barrier 约 15 μ s，小 batch 时约占算子 20%；真实跨机 decode 中约占 GPU step 的 15%–17%。
- **思想**：将“开始上传”和“允许写入目标 buffer”分开。INC 汇总 READY 的同时接收数据，就绪后转发。
- **贡献**：pre-barrier 开销测量、提前上传协议，以及完整通信操作的时延分析。

2. Background and Motivation — 背景与动机

2.1 Expert-Parallel Communication

介绍 Dispatch $\rightarrow$ expert compute $\rightarrow$ Combine。路由决定 token 的目标，计数和布局元数据决定接收后的组织方式。READY 表示本轮通信所需资源可用。

典型发送前协调方式：NCCL EP HT 先汇总路由；DeepEP V2 Direct 先执行 pre-barrier，再并行处理计数与数据；NCCL EP LL 向预留槽位写入并使用细粒度信号。

2.2 Pre-Barriers in DeepEP V2 Direct

Direct Dispatch/Combine 在 token 发送前等待参与 rank 就绪并完成本地同步。预分配 buffer 使地址可知，但目标 buffer 本轮是否允许覆盖仍需确认。

固定 EP8，T/rank 从 8 增至 128 时，pre-barrier 约保持 15 μ s，占比从约 20% 降至约 5%。这说明小 batch 下提前上传的机会值得研究。

2.3 Opportunities for In-Network Computing

INC 可在转发时维护哪些 rank 已就绪，并暂存早到 token。所有相关通信经过 INC 时，可将上传与 READY 汇总并行组织。

Key Insight：本地数据就绪后即可上传到网络暂存区，目标写入仍等待所需就绪条件。这样 pre-barrier 的等待过程可以与部分数据传输重叠。


3. Design — 设计

3.1 Overview and Assumptions

A Direct: wait, then upload



B INC: upload while collecting READY



Earlier upload; destination writes still wait for readiness.

INC 为每轮维护 READY bitmap 和有上限的数据队列。generation 标识一次 Dispatch/Combine，epoch 区分接收 buffer 的不同轮使用。相关参与者及数据路径需纳入相同的就绪判定范围。

接收 buffer 在初始化时按 symmetric memory 分配、注册，布局 and 访问映射一次性建立。token 路由和标识决定目标及写入偏移，不依赖全局计数。READY 确认本地输入可用，且目标 buffer 已结束上一轮使用。

3.2 Early Upload and Readiness Aggregation

rank 发布 READY 后开始上传，不等其他 rank 的 READY 返回。READY 携带 rank、generation、epoch；路由随 token 传输，必要计数和元数据按原通信流程处理，不把完整 count vector 作为 READY 的前置条件。

INC 忽略重复和旧轮次消息。所需 READY 未收齐时暂存 DATA；就绪且目标可写后，按路由转发缓存和新到 token。Dispatch 接收后按 expert 整理；Combine 将 expert outputs 送回 token owner 完成合并。

3.3 Buffer Management and Backpressure

接收 buffer 的最后一次读取完成后才可复用，下一轮 READY 确认这一点。发送 buffer 保留到发送硬件读完。INC 在队列排空且所有 rank 进入下一轮后回收旧轮 READY 状态。

PFC 在缓存溢出前暂停 DATA，并预留 headroom 接纳暂停生效前的在途数据。READY 与必要控制元数据有独立优先级和预留资源，避免暂停 DATA 时阻塞就绪消息。

4. Latency Analysis — 时延分析

4.1 Operation Latency


建模一次完整 Dispatch/Combine，从输入本地可用到所有 rank 完成。借鉴 Swift 区分处理与网络时延。

参考条件：rank 同时就绪、无明显拥塞，INC 维持基线数据转发速率。L 为单向传播和固定转发时延，S 为整次通信在瓶颈速率下传输全部 payload 的时间；H 为关键路径上未重叠的处理时间，C 为后续交付确认和本地收尾。


- 基线： $T_{\text{base}} = H_{\text{base}} + L + (S + L) + C$ 。
- INC： $T_{\text{INC}} = H_{\text{INC}} + (S + L) + C$ 。

4.2 How Early Upload Creates Overlap


A Simultaneous readiness: Direct




B Simultaneous readiness: INC



C Unequal readiness: Direct



D Unequal readiness: INC



Dashed: READY Solid: DATA Schematics show readiness and data delivery; spacing is illustrative.

基线先完成 READY 的端点间传播，再启动数据；INC 让 READY 与后续 DATA 一起向网络节点前进，条件满足后继续转发。因此参考收益为 $L + H_{base} - H_{INC}$ 。只有未被额外处理和排队抵消的提前量，才会缩短操作完成时间。

4.3 Unequal Readiness and Backpressure

rank 到达不一致时，早到数据可在 INC 等待；真正收益取决于晚到 rank、出口排队和 PFC。完整操作以最后一个 rank 完成为准，某个目标提前收到数据不必然等于全局操作加速。

5. Evaluation — 实验评估

5.1 Experimental Setup and Methodology

- 两台 H200，各八卡；机内 NVSwitch，机间八轨 400GbE RoCE。Direct、GDAKI3、TC162。
- 微基准：H=7168、topk=8、E=256、BF16、balanced/uniform。每点三轮独立进程，每轮 200 次有效迭代。
- 每次选 pre-barrier 最短的 rank，除以同 rank 同轮 trace-on 算子时间；先逐迭代计算，再对三轮均值取平均。误差为轮间标准差。
- 推理使用同 rank 的 pre-barrier 累计时间与 GPU step 配对，再跨 rank 和三个 client 窗口平均。

5.2 Pre-Barrier Cost

H200 跨机 EP8 Direct:

T/rank	Dispatch pre-barrier 占比	Combine pre-barrier 占比
8	(20.57 ± 0.06)%	(19.84 ± 0.13)%
32	(12.25 ± 0.17)%	(12.26 ± 0.26)%
64	(8.29 ± 0.51)%	(8.20 ± 0.16)%
128	(4.88 ± 0.04)%	(5.05 ± 0.19)%

四档绝对时长均约 15 μs；算子占比随 T 增大而下降。来源：配对数值；主图源码。

5.3 Dependence on EP Size

各固定 EP 配置的常数估计使用全部所列 token 档，每档三轮：

EP 卡数	T/rank	Dispatch (μs)	Combine (μs)	各档均值最大偏差 (μs)
4	8/32/96/128	11.65	11.54	0.06
8	8/32/64/96/128	14.96	14.94	0.16
16	8/32/96/128	18.36	18.28	0.09

固定 EP 时，pre-barrier 对 T 近似恒定。EP4/8/16 同时改变每机卡数、目标分布和网络并发，数值体现这些配置的综合变化。EP8 T=64 来自后续不同插桩批次。来源：拟合数值。

5.4 Pre-Barriers in MoE Inference

Qwen3-30B-A3B, BF16、TP1/EP8 Direct, 输入/输出各 128 token；实际路由，比较单机 1n8 和跨机 2n4：

拓扑	并发	实测 token/rank	D+C pre-barrier 占 GPU step
单机 1n8	64	8	9.33%
跨机 2n4	64	8	16.72%
单机 1n8	128	16	7.94%
跨机 2n4	128	16	15.19%

每个采样 step 含 48 次 Dispatch 与 48 次 Combine；三个 client 窗口使用同一 server 实例。占比分母为 GPU step。来源：推理数值、分项；主图源码。

6. Related Work — 相关工作

6.1 EP Communication

DeepEP 与 NCCL EP 提供 EP 数据路径与不同发送前协调方式。SwiftEP、Perseus、UBEP 改进数据移动和传输过程中的协调。本文用网络暂存重叠发送前的就绪等待。

6.2 In-Network Computation

SHARP、SwitchML 展示网内归约与状态管理；DySHARP、MultiWrite 将网络处理用于 MoE 数据交换。本文利用临时状态和缓存改变 pre-barrier 与上传的先后关系。

6.3 Synchronization and Delay Analysis

EPIC 的 INC 协议和资源抽象、GPU-Initiated Networking 的端点原语为实现提供基础。Swift 提供处理/网络时延分解思路，FabricPerf 强调明确的计时边界。

7. Conclusion — 结论

小 batch 下 pre-barrier 开销显著。INC 允许本地就绪的 rank 在等待期间提前上传，并在接收条件满足后转发。收益取决于暂存空间、就绪时间差和转发速率。