

Overlapping MoE Pre-Barriers with Data Transfer Using In-Network Computing

主线：rank 本地就绪后先上传，INC 同时收集 READY 并暂存早到数据；接收条件满足后转发，把等待其他 rank 就绪的时间用于搬运数据。

1. Introduction —引言

- 问题：小 batch 缩短 token 传输，但 pre-barrier 仍需等待同一组 rank，开销难以摊薄。
- 观测：H200 跨机 EP8 Direct 的 pre-barrier 约 15 μ s，小 batch 时约占算子 20%；真实跨机 decode 中约占 GPU step 的 15%–17%。
- 思想：将“开始上传”和“允许写入目标 buffer”分开。INC 汇总 READY 的同时接收数据，就绪后转发。
- 贡献：pre-barrier 开销测量、提前上传协议，以及完整通信操作的时延分析。

2. Background and Motivation —背景与动机

2.1 Expert-Parallel Communication

介绍 Dispatch $\rightarrow$ expert compute $\rightarrow$ Combine。路由决定 token 的目标，计数和布局元数据决定接收后的组织方式。READY 表示本轮通信所需资源可用。

典型发送前协调方式：NCCL EP HT 先汇总路由；DeepEP V2 Direct 先执行 pre-barrier，再并行处理计数与数据；NCCL EP LL 向预留槽位写入并使用细粒度信号。

2.2 Pre-Barriers in DeepEP V2 Direct

Direct 已采用 GPU 发起传输和预分配接收 buffer。Dispatch 由不同 warps 并行处理计数 / 布局和 token 传输，Combine 复用 Dispatch 建立的路由。

这些传输在 pre-barrier 之后开始：每个 rank 等待参与者就绪并完成本地同步，因此本地已有 token 也不能提前发送。固定 EP8，T/rank 从 8 增至 128 时，pre-barrier 约保持 15 μ s，占比从约 20% 降至约 5%。由此引出在收集 READY 时先上传本地数据的机会。

2.3 Opportunities for In-Network Computing

INC 可在转发时维护哪些 rank 已就绪，并暂存早到 token。所有相关通信经过 INC 时，可将上传与 READY 汇总并行组织。

Key Insight：本地数据就绪后即可上传到网络暂存区，目标写入仍等待所需就绪条件。这样 pre-barrier 的等待过程可以与部分数据传输重叠。

3. Design —设计

3.1 Overview and Assumptions

INC 为每轮维护 READY bitmap 和有上限的数据队列。generation 标识一次 Dispatch/Combine，epoch 区分接收 buffer 的不同轮使用。相关参与者及数据路径需纳入相同的就绪判定范围。


接收 buffer 在初始化时按 symmetric memory 分配、注册，布局和访问映射一次性建立。token 路由和标识决定目标及写入偏移，不依赖全局计数。READY 确认本地输入可用，且目标 buffer 已结束上一轮使用。

3.2 Early Upload and Readiness Aggregation


rank 发布 READY 后开始上传，不等其他 rank 的 READY 返回。READY 携带 rank、generation、epoch；路由随 token 传输，必要计数和元数据按原通信流程处理，不把完整 count vector 作为 READY 的前置条件。

INC 忽略重复和旧轮次消息。所需 READY 未收齐时暂存 DATA；就绪且目标可写后，按路由转发缓存和新到 token。Dispatch 接收后按 expert 整理；Combine 将 expert outputs 送回 token owner 完成合并。

A Direct: wait, then upload



B INC: upload while collecting READY



Earlier upload; destination writes still wait for readiness.

Figure 1: 前同步与提前上传

3.3 Buffer Management and Backpressure

接收 buffer 的最后一次读取完成后才可复用，下一轮 READY 确认这一点。发送 buffer 保留到发送硬件读完。INC 在队列排空且所有 rank 进入下一轮后回收旧轮 READY 状态。

PFC 在缓存溢出前暂停 DATA，并预留 headroom 接纳暂停生效前的在途数据。READY 与必要控制元数据有独立优先级和预留资源，避免暂停 DATA 时阻塞就绪消息。

4. Latency Analysis — 时延分析

4.1 Three-Stage Model

完整 Dispatch/Combine 分为 READY、DATA、post-barrier。DATA 包含进入后同步前必需的发送侧工作；后同步项包含本地收尾。

$$T_{\text{base}} = T_{\text{ready}} + T_{\text{data}} + T_{\text{post}}.$$

借鉴 Swift 区分处理与网络时延，在参与者同时就绪的参考条件下：

$$T_{\text{ready}} = T_{\text{issue}} + L + T_{\text{observe}}.$$

T_{issue} 是本地准备并发出 READY 的时间； L 是 READY 的单向网络传播； T_{observe} 是接收后检查信号与完成本地同步的时间。

4.2 Overlapping the Wait for READY

INC 保留本地发起工作，随后让 DATA 上传与 READY 传播重叠；目标写入仍等就绪条件满足。在参考数据传输和后同步工作相同的条件下：

$$T_{\text{INC}} = T_{\text{issue}} + T_{\text{data}} + T_{\text{post}} + T_{\text{extra}}.$$





T_{extra} 包括仍需执行的就绪处理及额外缓存 / 放行等待。DATA 自身的源到目标传播已包含在 T_{data} 中。

$$\text{收益 } \Delta T = L + T_{\text{observe}} - T_{\text{extra}}.$$

网络部分的参考收益是 L ：对称路径下约半个网络 RTT。其含义不是整个实测 pre-barrier 时长的一半，净收益还取决于观察工作和新增处理成本。

4.3 Readiness Skew in Practice

实际运行中，计算与调度差异使 rank 常常错峰就绪。Figure 2(C-D) 中早到 rank 在等待期间上传，最后一个 READY 到达后，INC 可直接转发缓存中的 token，无需再等源端接收 peer 信号后才启动上传，因此机制不依赖同步到达。

A Simultaneous readiness: Direct**B Simultaneous readiness: INC****C Unequal readiness: Direct****D Unequal readiness: INC**

Dashed: READY Solid: DATA Schematics show readiness and data delivery; spacing is illustrative.

Figure 2: READY 与上传重叠的时序对照

暂存和转发能力充足时，这一上传提前量能在错峰场景中保留；若提前了关键路径上的数据交付，就能缩短完整操作。出口排队和 PFC 的额外等待计入 T_{extra} ，收益大小随到达时序及最后完成的 rank 而变化。

5. Evaluation — 实验评估

回答三个问题：pre-barrier 如何随 token 数变化、在不同 EP 配置中是否持续存在，以及它在真实 MoE serving step 中占多大比例。

5.1 Experimental Setup and Methodology

- 两台 H200，各八卡；机内 NVSwitch，机间八轨 400GbE RoCE。Direct、GDAKI3、TC162。
- 微基准：H=7168、topk=8、E=256、BF16、balanced/uniform。每点三轮独立进程，每轮 200 次有效迭代。
- 每次选 pre-barrier 最短的 rank，除以同 rank 同轮 trace-on 算子时间；该口径减少慢 rank 到达差的影响，但选中 rank 仍可能等待。误差为三轮均值的样本标准差。
- EP8 token sweep 与 EP-size 表来自不同采集批次；表格常数只拟合表中列出的点。
- 同镜像 EP8/T8 on/off 检查中，Dispatch 总时延差 3.9%–5.0%，Combine 为 1.7%–3.8%；阶段占比使用同次 trace-on 分子与分母。
- 推理每个 client 窗口采样一个 active GPU step。decode 每个活跃 rank 均采样；prefill 只统计实际执行的 active step。

5.2 Pre-Barrier Cost versus Token Count

H200 跨机 EP8 Direct:

T/rank	Dispatch pre-barrier 占比	Combine pre-barrier 占比
8	$(20.57 \pm 0.06)\%$	$(19.84 \pm 0.13)\%$
32	$(12.25 \pm 0.17)\%$	$(12.26 \pm 0.26)\%$

T/rank	Dispatch pre-barrier 占比	Combine pre-barrier 占比
64	$(8.29 \pm 0.51)\%$	$(8.20 \pm 0.16)\%$
128	$(4.88 \pm 0.04)\%$	$(5.05 \pm 0.19)\%$

四档绝对时长均约 15 μ s；算子占比随 T 增大而下降。来源：[配对数值](#)；[主图源码](#)。

5.3 Across EP Configurations

各固定 EP 配置的常数估计使用全部所列 token 档，每档三轮：

EP 卡数	T/rank	Dispatch (μ s)	Combine (μ s)	各档均值最大偏差 (μ s)
4	8/32/96/128	11.65	11.54	0.06
8	8/32/64/96/128	14.96	14.94	0.16
16	8/32/96/128	18.36	18.28	0.09

固定 EP 时，pre-barrier 对 T 近似恒定。EP4/8/16 同时改变每机卡数、目标分布和网络并发，因此这些数值表示各配置的综合变化。来源：[拟合数值](#)。

5.4 Pre-Barriers in MoE Serving

Qwen3-30B-A3B, BF16, TP1/EP8 Direct, 实际路由。这里的占比是一个 sampled GPU step 内 48 次 Dispatch 与 48 次 Combine 的 pre-barrier 累计时间；不同于 §5.2 的单算子占比。

拓扑	并发	实测 token/rank	D+C pre-barrier 占 GPU step
单机 1n8	1	1	$(9.26 \pm 0.15)\%$
单机 1n8	64	8	$(9.33 \pm 0.12)\%$
单机 1n8	128	16	$(7.94 \pm 0.15)\%$
单机 1n8	256	32	$(7.61 \pm 0.32)\%$
跨机 2n4	64	8	$(16.72 \pm 0.10)\%$
跨机 2n4	128	16	$(15.19 \pm 0.05)\%$

C1 是低负载锚点，每个窗口只有一个 active rank；三个 client 窗口复用同一 server 实例。

扩展跨机对照：

EP	工作负载	T/rank	pre-barrier 占 GPU step
4	Decode C64	16	$(14.75 \pm 0.21)\%$
8	Decode C128	16	$(15.19 \pm 0.05)\%$
16	Decode C256	16	$(15.04 \pm 0.12)\%$
8	Prefill	512	$(2.64 \pm 0.06)\%$
8	Prefill	2048	$(3.13 \pm 0.39)\%$

在相同 16 token/rank 下，跨机 EP4/8/16 均约为 15%。大 token prefill 的占比降至约 3%，与小 batch decode 的趋势一致。prefill 行使用并发 1 和每窗口唯一 active step，是工作负载对照。来源：[扩展汇总](#)、[原始汇总](#)；[主图源码](#)。

6. Related Work —相关工作

6.1 EP Communication

DeepEP 与 NCCL EP 提供 EP 数据路径与不同发送前协调方式。SwiftEP、Perseus、UBEP 改进数据移动和传输过程中的协调。本文用网络暂存重叠发送前的就绪等待。

6.2 In-Network Computation

[SHARP](#)、[SwitchML](#) 展示网内归约与状态管理；[DySHARP](#)、[MultiWrite](#) 将网络处理用于 MoE 数据交换。本文利用临时状态和缓存改变 pre-barrier 与上传的先后关系。

6.3 Synchronization and Delay Analysis

[EPIC](#) 的 INC 协议和资源抽象、[GPU-Initiated Networking](#) 的端点原语为实现提供基础。[Swift](#) 提供处理/网络时延分解思路，[FabricPerf](#) 强调明确的计时边界。

7. Conclusion — 结论

小 batch 下 pre-barrier 开销显著。INC 允许本地就绪的 rank 在等待期间提前上传，并在接收条件满足后转发。收益取决于暂存空间、就绪时间差和转发速率。