

Overlapping MoE Synchronization with Data Transfer through In–Network Coordination

核心 idea：INC 在数据上传期间汇总 READY，并在目标尾包后追加 DONE，将同步与数据传输重叠。

1. 当前问题：小 batch 下，两端的同步往返难以摊薄

- 前同步：本地数据已就绪，仍需等 EP 组的 READY，才能开始发送。
- 后同步：发送收尾、flush 和本地汇合后，端点再发起完成 signal 交换。
- 小 batch 的影响：payload 变少，固定协调成本不会等比例下降。
- 研究对象：存在 EP 组入口与尾部协调的 DeepEP V2 跨机 Direct Dispatch/Combine，不将这一路径的同步行为推广到所有 EP 实现。

1.1 场景定位

Deepep-v2里的:跨机 Direct Dispatch / Combine：入口 barrier，以及发送完成 / 本地汇合后的全 EP 尾部协调

1.2 已有数据：证明问题的重要性

每次迭代取前同步耗时最短的 rank，除以该 rank 当次的算子时长，得到前同步占比。

H200 跨机 EP8 Direct, H=7168、topk=8、E=256、BF16、TC162/GDAKI3；T=32/64 是同配置的后续补测。误差为三轮间标准差：

T/rank	Dispatch 前同步	Combine 前同步
8	(20.57 ± 0.06)%	(19.84 ± 0.13)%
32	(12.25 ± 0.17)%	(12.26 ± 0.26)%
64	(8.29 ± 0.51)%	(8.20 ± 0.16)%
128	(4.88 ± 0.04)%	(5.05 ± 0.19)%

先逐迭代计算占比，再对三轮均值取平均。四档的前同步均约 15 μs，占算子的比例随 T 增大而下降。

真实模型中的位置。Qwen3–30B–A3B, BF16，固定 EP8、Direct、decode 输入/输出各 128 token，比较单机与跨机：


拓扑	并发	实测 token/rank	D+C 前同步占 GPU step
单机 1n8	64	8	9.33%
跨机 2n4	64	8	16.72%
单机 1n8	128	16	7.94%
跨机 2n4	128	16	15.19%

在相同 EP 规模和并发下，跨机的前同步占比约 15%–17%，高于单机的约 8%–9%。

2.1 借鉴 Swift：把端点与网络时延分开

时延分解：把端点处理与网络传输分开

基于 Swift Fig. 2 重绘 · 六个事件时间戳，解释一轮 DATA / ACK 的往返



Adapted from Swift, SIGCOMM 2020, Fig. 2 · 网络残差仍可能包含未单独测出的发送排队

依据 Swift, SIGCOMM’20, Fig. 2 / §3.1–§3.3 重新绘制，保留原时间戳和分解公式。

迁移到 EP	具体内容
发送端	READY / DATA 发起、flush、局部汇合
fabric	传播、序列化、排队、INC 暂存与处理
接收端	数据可见、signal 观察、本地消费条件


本文借用时延分解方法；实测 gate 含端点成本，不能直接等同于半个网络 RTT。

2.2 一般情况：各 rank 独立就绪，INC 重叠两端协调

INC 的两项收益：提前上传，随尾包通知完成

上排：一般到达情况 下排：理想参考 颜色区分两个发送方向，线型区分数据与控制

—— 实线：DATA - - - - 虚线：READY / 完成 signal - - - - 绿色尾标：DONE 斜线区：暂存等待



理想参考： $L = RTT_{fabric} / 2$ ；前后各约减少 L ，另计 INC 开销。一般情况由就绪偏斜、尾部暴露与出口服务共同决定。

收益	基线	INC	省在哪里
前同步	sender 等其他 rank READY 后才上传	本 rank 就绪即上传；INC 暂存早到数据，READY 收齐后放行	其他 rank 的准备和信号传播期间，上行传输已在进行
后同步	sender 收尾 / 汇合后再产生全 EP 完成 signal	INC 根据预期数量识别目标尾部，紧随最后 DATA 产生 DONE	目标通知不再串行等待 sender 返回完成协调路径

一般到达时序。各 rank 可以在不同时间就绪：

- 基线上传：同时满足自己就绪与所需 peer READY 到齐。
- INC 上传：自己就绪、发出 READY，且网络暂存已获准。
- INC 放行：相关 READY 收齐，目标本轮可写，出口可服务。
- 慢 rank 与出口瓶颈仍然存在；缓存覆盖率不等于算子加速比。

实际收益按同一关键路径核算：

净收益 = 前侧被重叠的等待 + 后侧减少的暴露等待 - 新增开销

后同步信号窗口。 H200 跨机 EP8 Direct，测量从完成 signal 发起到所需 signal 全部观察；每档三轮、每轮 200 次有效迭代，T=32 合并两批共六轮。表中为绝对时长（μs，均值 ± 轮间标准差）：

T/rank	Dispatch	Combine
8	13.97 ± 0.04	13.56 ± 0.24
16	13.98 ± 0.23	13.78 ± 0.18
32	11.67 ± 0.94	11.70 ± 1.43
64	11.81 ± 0.42	11.76 ± 0.29
96	11.12 ± 0.22	11.24 ± 0.92
128	11.73 ± 0.07	11.88 ± 0.18

T≤16 约为 14 μs，已测的 T≥32 约为 11–12 μs，但 T=32 波动较大，不能据此认定存在协议切换。窗口仍含端点轮询和 peer 就绪等待，不等于 INC 可全部消除的时间；[完整逐轮数据与代码分析](#)。

同时开始是理想特例。 若路径对称、DATA 服务能力不变，且两侧各暴露一次单向控制传播：

L = RTT_fabric / 2
前侧 ≈ L，后侧 ≈ L；净收益 ≈ RTT_fabric - 新增开销

这个特例解释“两次半 RTT”的来源；真实 Direct 用实际时间戳判断暴露了多少。

2.3 数据分析：前同步随 token 数近似不变

令 T 为 token/rank，P 为 EP 卡数。固定 P、H/topk/E 与链路配置时，跨机 Direct 的 rank–min 前同步在小 batch 区间近似为常数。


EP 卡数	拟合 T/rank	Dispatch a (μs)	Combine a (μs)	各档均值最大偏差 (μs)
4	8/32/96/128	11.65	11.54	0.06
8	8/32/64/96/128	14.96	14.94	0.16
16	8/32/96/128	18.36	18.28	0.09

本区间内所有可用 T 档均参与常数拟合，每档三轮；EP8 的 T=64 来自后续同配置、不同插桩批次补测。结果只说明**各固定 EP 配置下，前同步对 T 近似恒定**，不推断任意卡数的规律；后同步暂不拟合：§2.2 的窄完成 signal 数据只覆盖 EP8，原宽 post 又包含数据传输。详见 [拟合记录与计时边界诊断](#)。

3. INC 设计

INC：就绪汇总与上传重叠，完成通知随尾包送达

资源前提：预留端点缓冲区和有界网络暂存；本轮可写状态由 READY 确认



Dispatch：转发 activation，可结合组播

Combine：按 contributor 集合归约，再有序写回结果

可编辑矢量图

- **保留状态**：本轮标识、READY 集合、目标预期数量、写出进度。
- **Dispatch**：转发 activation，可结合已有 multicast。
- **Combine**：复用 Dispatch 建立的 contributor 集合，完成网内归约后写回结果。
- **贡献边界**：同步与传输的时序重叠；multicast/reduction 的带宽机制沿用已有工作。

4. 场景限定条件

4.1 四个成立条件

1. **资源与轮次**：使用合法的本轮 staging；消费结束后才可复用，每个 DATA 必须写到本轮合法的 staging buffer。即使 INC 已经发了 DONE，buffer 也不能立即给下一轮复用，因为目标 GPU 的后继算子可能还在读取它。
 2. **有序可见，即Fence**：目标观察到 DONE，必须意味着其覆盖的数据已对 GPU 可见。
 3. **流量必须都经过INC**：INC 只判断受管流量；如果有其他bypass路径，那么管理复杂度会显著上升，因此场景仅限于流量均经过INC的；
- 关于“机内”/“机外”的问题：感觉主要是是否保序，机外一般是保序的，机内一般不保序，因此需要做Fence（需要确保后同步的Done在到达的时候，所有数据都需要传输完毕）；并且机外的同步占比一般更高一些？
4. **容量与进展**：暂存有上限，压力沿同路背压；READY 等控制消息不能被等待中的 DATA 堵死。

4.2 当前已有证据

证据	支撑的结论
Direct 内核与 GDAKI 源码	前后协调阶段确实存在
H200 跨机 Direct, 小 batch 三轮对照	rank-min: T=8 时前同步约占对应 rank 算子 17%—21%; 各固定 EP 配置下, T=8—128 各档均值离常数拟合最多 0.16 μ s
H200 Direct 尾部细分	原宽 post 覆盖数据工作和排空; 独立 signal 发起/观察窗口在 EP8、T=8 时约占对应算子 18%—19%, T=128 时约 4%, 含端点和 peer 就绪成本
Qwen3—30B—A3B 跨机推理	EP8、decode 并发 64/128 时, 前同步本身占被选 GPU step 约 16.72%/15.19%; 前后并集合计还包括含数据收尾的 post
Swift 分解与本文模型	解释重叠和尾通知的收益条件

路径判定依据：[Direct Dispatch](#)、[Direct Combine](#) 与 [GIN 保序语义](#)；完整核对见 [路径记录](#)。

5. Related Work

5.1 EP 通信、同步与重叠

工作	核心做法	与本文的关系 / 区别
Deep EP	为 MoE Dispatch/Combine 提供低时延、高吞吐、Direct 与 Hybrid 路径	是本文主要基线与场景来源；本文不替换其数据路径，而是尝试把特定路径中暴露的 READY 和完成协调移入网络并与 DATA 重叠
NCC L EP	LL 面向小 batch，采用直接 RDMA+NVLINK mesh 和双缓冲；HT 面向大 batch，采用机内汇聚后的分层传输	展示两类端点数据路径；本文只在其确有暴露同步依赖时比较，不声称所有 LL/HT 路径都存在双 barrier
Swift EP	通过 buffer fusion、TMA offload 和传输优化减少拷贝与 GPU 开销	优化 DATA 如何搬运；本文研究 DATA 何时可上传、何时可安全宣布目标完成，两者可以叠加
UEP	以 GPU—CPU 控制通道和 CPU proxy 提供跨硬件的 EP 通信与顺序语义	关注可移植传输及端点代理；本文把动态 READY 汇总和目标完成判定放在网络会合点
Pers eus	将每个 tile 的 PUT 与 completion signal 解耦，并用 NIC fence flag 保序，减少 proxy/NIC 流水线串行化	优化的是已启动 RDMA 传输内部的 PUT/fence/signal 顺序开销；不汇总跨 rank READY，也不以 INC 暂存早到 DATA 或产生逐目标 DONE
UBE P	在 CM384 上分解 BSP Dispatch 流水，以点对点信号和 Data-as-Flag 替代其中的 SyncAll 与显式 barrier	优化的是EP 数据传输流水内部的阶段同步和到达验证；它依赖预分区接收地址及 UB Fabric 的 512 B 原子 load/store，不提供本文的网内 READY 汇总、暂存放行和 fabric 侧逐目标 DONE

5.2 MoE 与动态 INC 数据面

工作	核心做法	与本文的关系 / 区别
DySHA RP	用动态 in-switch addressing、multicast/reduction 与 token-centric fusion 加速 MoE	提供可复用的 INC 数据面；本文不把 multicast/reduction 的带宽收益作为贡献，而关注这些动作前后的同步关键路径
MultiW rite	用 multicast 语义消除 many-to-many 通信中的重复上行	减少 Dispatch 流量；不负责动态 READY 汇总、暂存放行或目标完成判定

5.3 网内集合通信与同步卸载

工作	核心做法	与本文的关系 / 区别
SHARP / SHARPV3	将 reduction、broadcast 等集合通信操作卸载到网络	面向已建立的集合操作；本文处理 MoE 中随路由变化的就绪集合、目标流量计划与完成条件
SwitchML	端网协同实现交换机内模型梯度聚合	提供 reduction 状态管理先例；其规整 dense aggregation 不包含本文的未同步上传和逐目标尾通知
EPIC	为以太网 INC 提供可编程协议与资源抽象	可作为本文机制的潜在承载平台；本文贡献是 MoE 专用的事件语义和时序，而非通用 INC 架构
GPU-Initiated Networking	向 GPU 提供 PUT、signal、fence 等设备侧网络原语	是基线路径的传输构件和保序基础；它不自行聚合跨 rank READY 或判断每个目标的动态完成条件

5.4 时延模型、观测与背压

工作	核心做法	与本文的关系 / 区别
Swift	以端点与 fabric 时间戳分解网络时延	本文借用其分解方式建立统一模型；不重新提出拥塞控制算法
FabricPerf	细粒度观测 GPU scale-up 通信	为事件与关键路径测量提供方法参考；本文还需单独测量跨机 Direct 的 READY、DATA 与 DONE 事件
IEEE 802.1Qbb PFC	在链路压力下暂停无损优先级流量	可保护暂存主路径，但不能替代容量准入、轮次隔离、控制消息进展或端到端可见性语义

本文的位置。尾随 DATA 的 signal、网内 multicast/reduction 和设备侧 barrier 都已有先例。本文要新增并验证的是它们在跨机 EP 同步中的组合与放置：rank 就绪后无需等待全组 release 即上传，网络以有界暂存吸收早到 DATA；会合点汇总动态预期流量，并在每个目标的最后 DATA 之后产生有序 DONE。核心基线是 DeepEP/NCCL EP 的具体路径；DySHARP 用于划清 INC 数据面边界，Perseus 与 UBEP 用于区分已有的传输内部保序和阶段同步优化。